kurs-r-viderekomne

Innhold

1 R for viderekomne

Velkommen til kurset! Dette er et kurs for de som har litt R programmering fra før.

- Indexering av vektorer
- Forklaring av forkjellige datasett typer
- Kontroll setninger med if og else
- For- og while-løkker
- Hvordan å skrive funksjoner
- Tips til feilsøking
- Andre ting og vei videre

2 Indeksering

Vektorer samler flere verdier til et objekt. De må har samme type innehold (for eks. alle numeriske). Vi kan beregne direkte på alle elementer i en vektor. For eks:

```
alder <- c(49, 39, 51, 73, 41)
alder * 2
```

```
[1]  98  78 102 146  82
```

Vi kan kjøre tester på alle elementer i en vektor. For eks:

```
alder == 39
```

```
[1] FALSE  TRUE FALSE FALSE FALSE
```

2.1 Indeksering

Ved bruk av `[ ]` kan vi hente ut elementer i en vektor (eller datasett). I R (i motsetting til Python), starter indeksering fra 1! For å hente ut første element for eks:

```
alder[1]
```

```
[1] 49
```

For å ekskludere et element kan vi bruke -indeks. For eks:

```
alder[-1]
```

```
[1] 39 51 73 41
```

For å hente ut flere elementer kan vi spesifisere et sekvens

```r
alder[1:4]
```

```
[1] 49 39 51 73
```

Vi kan også bruke indeksering til å endre et spesifikk element. For eks:

```r
alder[1] <- 48
alder[1]
```

```
[1] 48
```

3 Data typer

Lister samler objekter/vektorer/datasett. De kan har forskjellige type og størrelser.

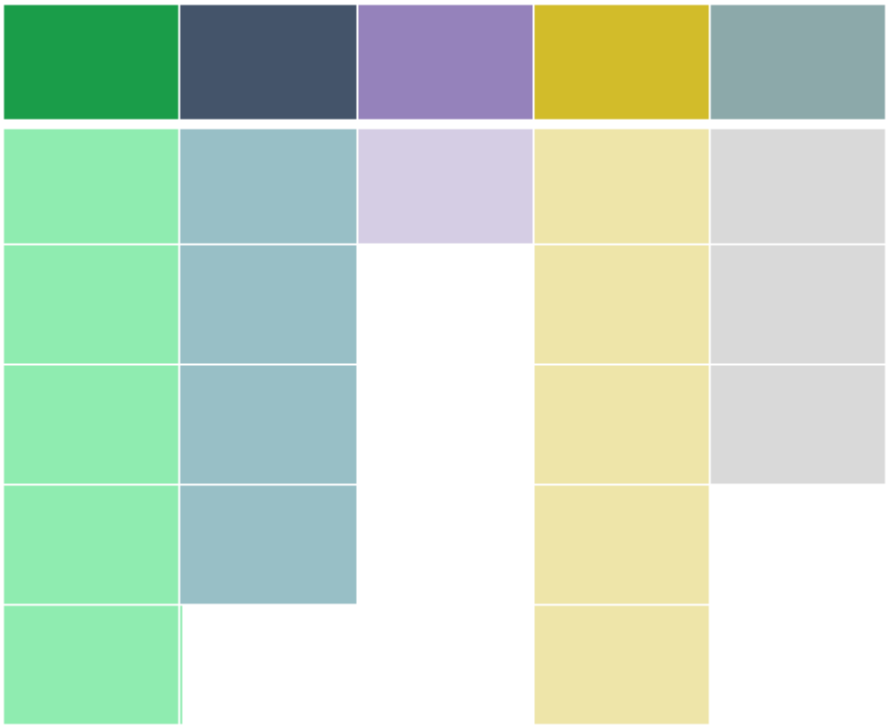

Vi lager lister ved å bruke `list()`.

```
kommune_list <- list(sted = c("Oslo", "Kongsvinger", "Halden"),
                     snitt_lonn = c(636, 504, 552),
                     antall_lonnstakere = c(467400, 8300, 12600),
                     nivaa = "Kommune")
kommune_list
```

```
$sted
[1] "Oslo"        "Kongsvinger" "Halden"
```

```
$snitt_lonn
[1] 636 504 552

$antall_lonnstakere
[1] 467400   8300  12600

$nivaa
[1] "Kommune"
```

Vi kan bruke **$** for å få tilgang til et vektor eller element i en liste.

```
kommune_list$snitt_lonn
```

```
[1] 636 504 552
```

Vi kan kombinere dette med `[ ]` for å hente ut elementer.

```
kommune_list$snitt_lonn[1]
```

```
[1] 636
```

3.1 Datasett

Datasett er lister som samler vektorer med samme lengde.

Vi bruke `data.frame()` for å lage en vanlig R datasett

```
kommune_data <- data.frame(sted = c("Oslo", "Kongsvinger", "Halden"),
                           antall_lonnstakere = c(467400, 8300, 12600))
```

Igjen, vi kan bruke **$** for å få tilgang til et vektor og `[ ]` for å hente ut elementer.

```
kommune_data$snitt_lonn[2]
```

```
NULL
```

NB: I *tidyverse* bruker vi variabelnavn istedenfor $.Dette har konsekvenser for kjøretid og noen begrensninger men *tidyverse* er veldig intuitiv og givende pakke for analysering av data.

Noen nyttige funksjoner som kan benyttes ved datasett

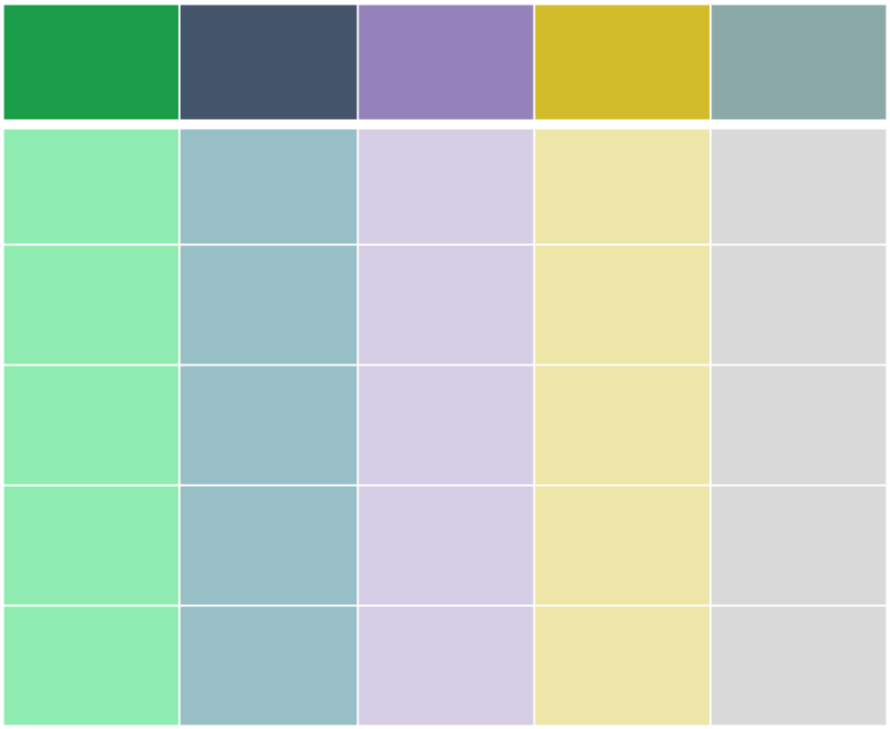

Figure 3.1: Eksempel datasett

```r
nrow(kommune_data)
```

```
[1] 3
```

```r
ncol(kommune_data)
```

```
[1] 2
```

```r
head(kommune_data)
```

```
         sted antall_lonnstakere
1        Oslo              467400
2 Kongsvinger                8300
3      Halden               12600
```

```r
library(tidyverse)
glimpse(kommune_data)
```

```
Rows: 3
Columns: 2
$ sted               <chr> "Oslo", "Kongsvinger", "Halden"
$ antall_lonnstakere <dbl> 467400, 8300, 12600
```

3.2 Forskjellige datasett typer

Det er forskjellige måte å formatere data i R. Disse er mest vanlig:

Data frame type	Code for formatting
Normal data frame	`data.frame()`
tibble (tidyverse)	`as_tibble()`
data table (data.table)	`data.table()`

4 Kontroll

For å sammenlign og gjøre noe baserte på en betingelse kan vi bruke **`ifelse()`**. Spesifisere betingelsen først, og så hva skal returnere ved sann, og så hva ska returneres om betingelsen er usann.

For eksempel:

```
alder <- c(49, 39, 51, 73, 41)
ifelse(alder < 50, "ungere", "eldere")
```

```
[1] "ungere" "ungere" "eldere" "eldere" "ungere"
```

Dette kan brukes for å lage nye variabler i et datasett. For eksempel

```
library(tidyverse)
```

```
-- Attaching packages --------------------------------------- tidyverse 1.3.2 --
v ggplot2 3.4.0      v purrr   1.0.1
v tibble  3.1.8      v dplyr   1.0.10
v tidyr   1.2.1      v stringr 1.5.0
v readr   2.1.3      v forcats 0.5.2
-- Conflicts ------------------------------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
```

```
dt <- data.frame(id = 1:5, alder)
dt %>%
  mutate(alder_kat = ifelse(alder < 50, "ungere", "eldere"))
```

```
  id alder alder_kat
1  1    49    ungere
2  2    39    ungere
3  3    51    eldere
4  4    73    eldere
5  5    41    ungere
```

4.1 Store prosesser

For å kontrollere store/lengere prosesser kan vi benytte **`if`** og **`else`**. Disse kan gå overe flere linjer og ta format:

```
if (betingelsen){
  gjør dette kode ...
} else {
  gjøre dette istedenfor ...
}
```

For eksempel:

```
if (all(dt$alder < 70)){
  print("Alle IOer er under 70")
} else {
  print("Alle IOer med alder 70+ er fjernet.")
  dt %>%
    filter(alder < 70)
}
```

```
[1] "Alle IOer med alder 70+ er fjernet."
```

```
  id alder
1  1    49
2  2    39
3  3    51
4  5    41
```

5 Løkker

For å gjøre den samme prosessen flere ganger kan vi lage løkker. Løkker har noen fordeler:

- Vi slipper å skrive den samme koden flere ganger.
- Enklere å endre noe verdier/variabler i koden (kun ett sted).
- Hvis vi finner en feil, da trenger vi kun å rette det ett sted.

For-løkker brukes til å kjøre gjennom kode et bestemt antall ganger

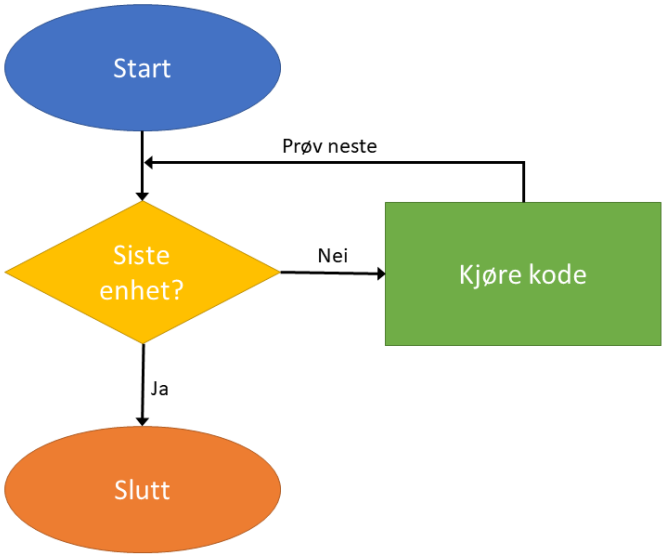

Det er vanlig å kjøre gjennom en sekvens. For eks:

```
alder <- c(49, 39, 51, 73, 41)

for (i in 1:5){
  print(i)
  print(alder[i])
```

```
}
```

```
[1] 1
[1] 49
[1] 2
[1] 39
[1] 3
[1] 51
[1] 4
[1] 73
[1] 5
[1] 41
```

Vi kan også lage løkker med en vektor. For eks:

```
for (a in alder){
  print(a)
}
```

```
[1] 49
[1] 39
[1] 51
[1] 73
[1] 41
```

5.1 While-løkker

While-løkker sjekk en betingelse for å bestemme om det skal fortsette å kjøres.

For eksempel:

```
n <- 1
while (n < 10){
  print(n)
  n <- n + runif(1)
}
```

```
[1] 1
[1] 1.270369
[1] 1.862685
[1] 2.403749
[1] 3.378416
[1] 3.698884
[1] 3.99482
[1] 4.160578
[1] 4.33379
[1] 4.560662
[1] 4.64436
[1] 5.1648
[1] 6.006314
```

```
[1] 6.292058
[1] 6.302363
[1] 7.288109
[1] 7.667218
[1] 8.201359
[1] 8.89194
[1] 9.105733
[1] 9.288099
```

```
n
```

```
[1] 10.15349
```

While-løkker brukes ofte i prosesser som har et tilfeldig komponent. I eksempel over, `runif()` funksjonen trekkes et tilfeldig tall mellom 0 og 1.

6 Funksjoner

En funksjon er en del av kode som kan brukes om-og-om igjen. Den har en input (det som sendes inn til funksjonen) og en output (det som kommer ut).

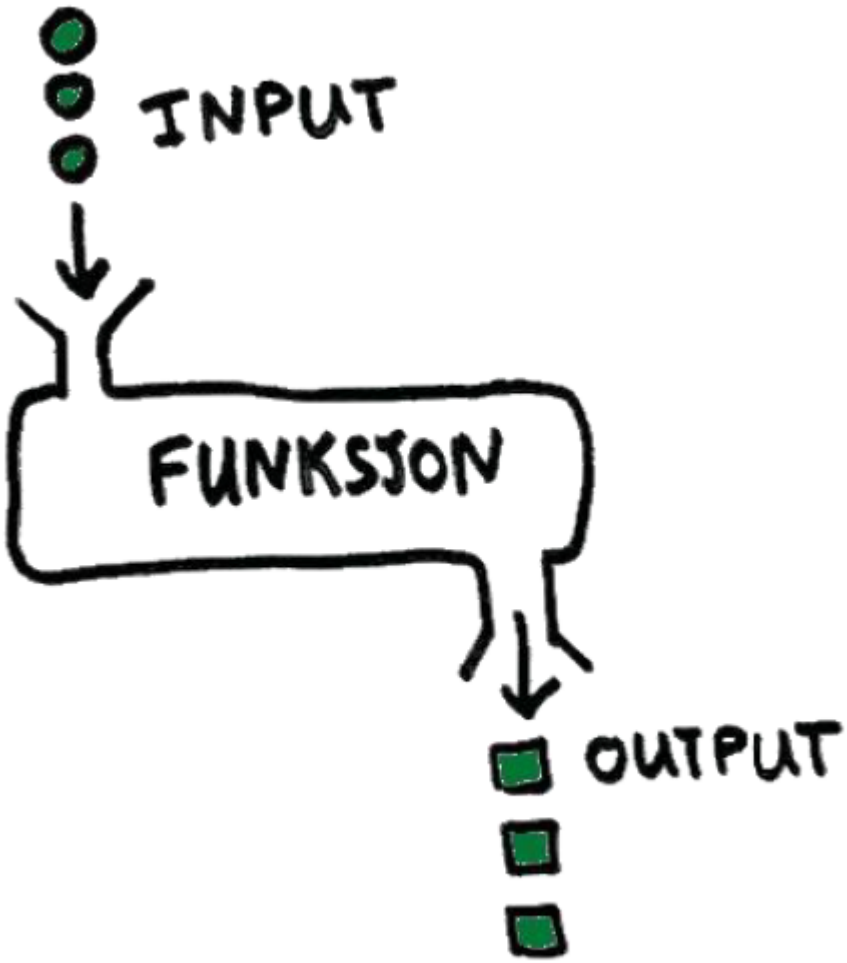

Parameter er tilleggsinformasjon som sendes inn til funksjonen for å spesifisere mer.

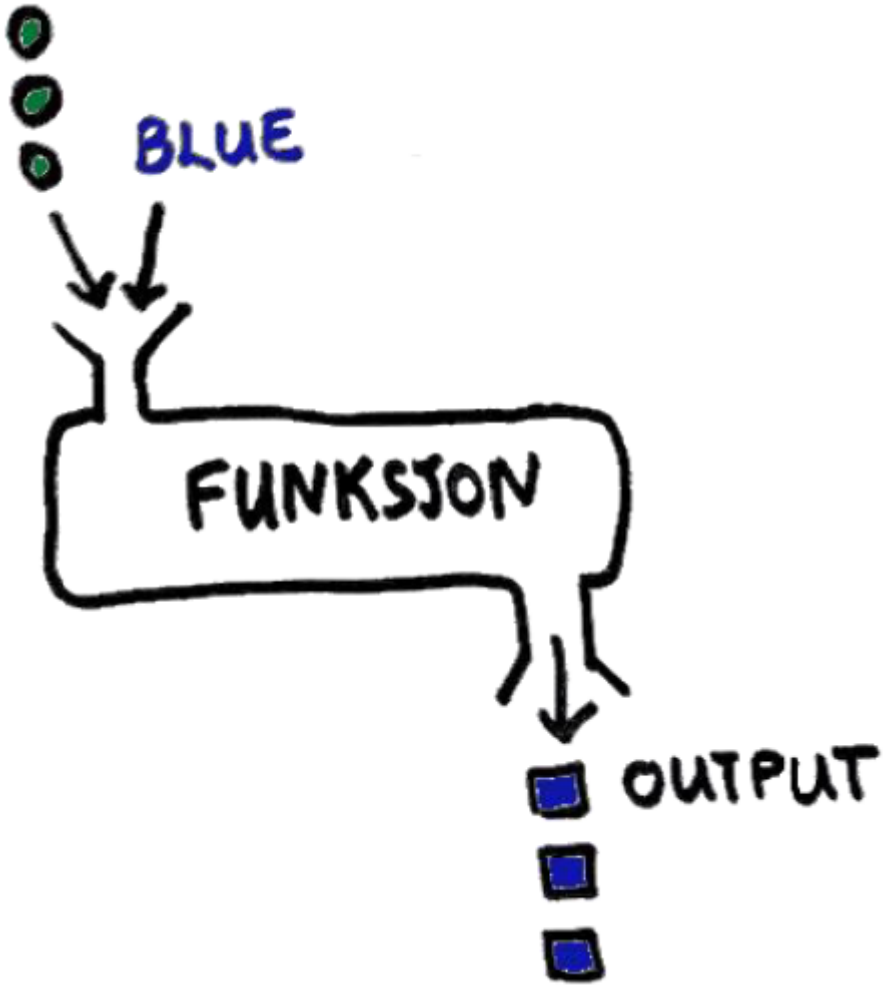

Bruk av funksjoner kan være nyttig: - Gjenbruk - Abstraksjon (trenger ikke å vite hvordan)

6.1 Lage en enkel funksjon

Vi lager en funksjon ved å allokere det et navn og spesifisere `function()`. For eks

```
min_func <- function(){
  print("hello")
}
```

Og etterpå kjøre vi funksjonen ved

```
min_func()
```

```
[1] "hello"
```

6.2 Lage en funksjon for fylke

Her skal vi lage en funksjon som ta kommunenummer som input og returnere fylkenummer. Vi spesifisere kommunenummer som en parameter i funksjonen. Vi bruker `substr()` for å plukke ut de første to siffer.

```
lage_fylke <- function(kommunenr){
  substr(kommunenr, 1, 2)
}

lage_fylke("0301")
```

```
[1] "03"
```

Funksjoner kan gå over flere linjer. Den siste linjen er det som returneres. Det kan også spesifiseres med `return()` ved behov, særlig i kompleks funksjoner med multiple output.

6.3 Flere parameter

Funksjoner kan ta mer enn èn paramter. For eksempel i fylke-funksjonen vi kanskje ønsker å sjekke lengde for å se om ledende 0-er har falt av.

```
lage_fylke <- function(kommunenr, sjekk_lengde){
  if(sjekk_lengde == TRUE){
    kommunenr <- ifelse(nchar(kommunenr) == 3,
                        paste("0", kommunenr, sep = ""),
                        kommunenr)
  }
  fylke <- substr(kommunenr, 1, 2)
  fylke
}
```

```
lage_fylke(kommunenr = "301", sjekk_lengde = TRUE)
```

```
[1] "03"
```

```
lage_fylke(kommunenr = "301", sjekk_lengde = FALSE)
```

```
[1] "30"
```

6.4 Standard/default parameter

Vi kan sett et parameter verdier for å slippe å spesifisere hver gang. For eksemepel, samme funksjon over kan har `sjekk_lengde=TRUE` som standard.

```
lage_fylke <- function(kommunenr, sjekk_lengde = TRUE){
  if(sjekk_lengde == TRUE){
    kommunenr <- ifelse(nchar(kommunenr) == 3,
                        paste("0", kommunenr, sep = ""),
                        kommunenr)
  }
  fylke <- substr(kommunenr, 1, 2)
  fylke
}

lage_fylke("301")
```

```
[1] "03"
```

Noen ganger kalles disse for "named parameters" eller "keyword arguements". Standard parameter alltid kommer til sist

6.5 Global vs Lokal-miljø

Når vi lage en funksjon, lage vi en liten lokal-miljø. Varaiabler som lagres inn i en funksjon påvirke ikke global-miljø og er slettet når funksjonen er ferdig-kjørt. For eksempel om vi har en enkel function som returneres verdien av parameter `x` vil ikke dette påvirke om vi har en x i det global-miljøet:

```
funcx <- function(x){
  x
```

```
}
```

```
x <- 2
funcx(x = 4)
```

```
[1] 4
```

```
x
```

```
[1] 2
```

6.6 Varsling i funksjoner

Noen ganger øsnker vi at funksjonen si ifra om noen er litt rart eller feil. For at funksjonen skal stoppe bruk **`stop()`**. For at det skal gi et varsel bruk **`warning()`**.

For eksempel, her stoppe funksjon om kommunenr er kun 2-siffer. Ved 3-siffer gis et varsel at en ledende 0 er lagt på.

```
lage_fylke <- function(kommunenr){
  if (nchar(kommunenr) <= 2){
    stop("Kommune nummer var ikke gjeldig.")
  }
  if (nchar(kommunenr) == 3){
    warning("Kommunenummer er lendge 3 og har blitt fylt med en ledende 0\n")
    kommunenr <- paste("0", kommunenr, sep = "")
  }
  fylke <- substr(kommunenr, 1, 2)
  fylke
}
```

```
lage_fylke(kommunenr = "03")
```

```
Error in lage_fylke("03") : Kommune nummer var ikke gjeldig.
```

```
lage_fylke(kommunenr = "301")
```

```
Warning in lage_fylke(kommunenr = "301"): Kommunenummer er lendge 3 og har blitt fylt med en
```

```
[1] "03"
```

```
lage_fylke(kommunenr = "0301")
```

```
[1] "03"
```

7 R feilsøking

Det kan være frusterende å programmere når det oppstår feil. Det er ikke alltid lett å forstå feilmeldinger, særlig hvis du er ny til R.

Feil kan klassifiseres som "kode" eller "tekniske". Kode-feil oppstår når vi programmere ting litt feil, for eksempel bruke funksjoner på en feil måte. Disse type feil kan vi mest ofte finne hjelp på nett og rette opp selv. Tekniske feil kan oppstår hvis vi mangler andre applikasjoner eller pakker, når vi prøve å kjøre R på forskjellige platform/ sammen med andre verktøy osv. I noen tilfelle kan vi løse disse selv men andre ganger trenger vi støtte fra IT.

7.1 Tips til feilsøking av kode

7.1.1 Generelle

- Kjør kode linje-ved-linje for å isolere feilen.
- Kopiere feilmelding du får inn til google (rense bort variabel/datasett navn osv først).
- For skriving av egen-funksjoner det kan hjelpe å sette inn noen print-setninger for å se hvor det stopper opp. Eller bruk debug().
- Sjekk at data er formatten som forventet (tibble vs. data.frame)
- Prøv å spørre Chatgpt
- Skriv om hjelp på yammer.

7.1.2 Spesifikk

Vanlige feilmeldinger	Tips
"argument is of length zero"	Se statology
"could not find function"	Sjekk at du har stavet riktig (små og store bokstaver). Sjekk at pakken er installerte og kalt inn.
"subscript out of bounds"	Sjekk at indeks ikke er for stor (utenfor vektor/datasett)
"no applicable method"	Sjekk at data er i format som forventet (eg data.frame, tibble, data.table osv)

Vanlige feilmeldinger	Tips
"cannot open file"	Sjekk at du har stavet filnavn riktig. Og sjekk filsti. Hvor er du? Bruk `getwd()`. Navigere til foreldre mappen ved .. i sti. Bruk Sys.getenv("ARBTAKER") for å hente inn miljøvariabler. DU kan også skriv ut alle filene ved `list.files()`

7.2 Tips til feilsøking av tekniske problemer

7.2.1 Generelle

- Kopiere feilmelding inn til google.
- Send en melding til kundeservice. Prøv å beskrive problemet. Lim inn feilmelding og kode du har kjørt.
- Hvis det er på Dapla - skriv på Slack: 'hjelp_dapla'. Gjerne prøve å lage et lite eksempel av når problemet oppstår som kalles et Minimal reproducible example

7.2.2 Spesifikk

Feilmeldinger	Tips
shiny	• Bruker du jupyter? – Bruk wrapper funksjon i +fellesr
pakke installering	• Bruk renv :-) – første gang: kjør `renv::init()` – bruk `renv::install('<pakker>')` for å installere – Ikke står på hjemmeområde men i en prosjektmappe. – Hvis "no package available", sjekk i renv.lock at URL er riktig ∗ URL skal ha "nexus.ssb.no" i navn – For multi-mappe prosjekter - har en renv i hovedmappen ∗ bruk `renv::autoload()` i notebookene

Feilmeldinger	Tips
Git	• Mangler git fane i RStudio? – Hvis du har en lokal RStudio på PC sjekk ut happygitwithr • Får ikke commit? – Husk å skrive inn en melding før du trykker på commit knappen. • Pull/push knapp er grå? – Har du noen endringer/commits til å pushe? – Bytte til kommandoer for å sjekke status med `git status` – Evt. bruk kommandoer istedenfor knapper

8 Videre bruk av R

`klassR` pakken er utviklet i SSB for å lett hente ut klassifikasjoner og kodelister fra KLASS. Mer info om hvordan å bruke pakken ligger i en introduksjon til klassR pakken

8.1 Metodebibliotek

Seksjon for Metoder har samlet nyttige metodiske funksjoner for bruk i et statistikk produksjonsløp. Både interne og eksterne utviklet funksjoner er inkluderte og har blitt testet. Metodebiblioteket er under utvikling men er tilgjengelig for alle på GitHub.

8.2 fellesR

R-pakken `fellesR` er en samling av funksjoner som kan være nyttige for flere på SSB. Alle er velkommen til å bidra med egne funksjoner om de synes andre kan har nytte av det. Flere av de funksjoner skal vi går gjennom i et nytt kurs 'R i produksjon'.

8.3 kurs: R i produksjon

Vi skal holde et nytt kurs med tips og anbefalinger om hvordan å bruke R i en produksjon setting. Tema for kurset inkluderer:

- innlesning av parquet-filer på Dapla
- pakkehåndtering med `renv`
- opplasting til Statbank
- kjøring av R og python i jupter notebooks
- generelle tips til organisering av kode